

Analyse de la situation sanitaire en Afrique de l'Ouest

1. Titre du projet

Analyse de la situation sanitaire en Afrique de l'Ouest : Tableau de bord sur le paludisme et la mortalité maternelle au Sénégal

2. Certificat concerné

- Data Analysis

3. Niveau de difficulté

- Débutant avancé

4. Pré-requis

- Python (bases : variables, fonctions, boucles)
- Manipulation de données avec Pandas
- Notions de visualisation avec Matplotlib ou Seaborn
- Familiarité avec les fichiers CSV/Excel
- Connaissance basique de Power BI ou Tableau Public (prise en main)
- Git et GitHub (commits, push, création de dépôt)

5. Durée estimée

Durée totale : 30 à 40 heures (tenable sur 3 semaines)

Répartition indicative :

- Compréhension du problème et exploration des données : 4 heures
- Nettoyage et préparation des données : 5 heures
- Analyse exploratoire (EDA) : 5 heures
- Construction du tableau de bord : 8 heures
- Déploiement ou démonstration : 3 heures
- Documentation et présentation : 5 heures

6. Contexte et problématique

L'Afrique de l'Ouest est l'une des régions du monde les plus touchées par les maladies évitables, notamment le paludisme et les complications liées à la grossesse. Le Sénégal, comme de nombreux pays de la sous-région, doit faire face à des défis sanitaires importants malgré les progrès réalisés au cours des deux dernières décennies.

Quel problème cherche-t-on à résoudre ?

Les décideurs publics, les ONG de santé et les agents de terrain disposent rarement d'outils visuels accessibles pour suivre l'évolution des indicateurs sanitaires clés (incidence du paludisme, taux de mortalité maternelle, couverture vaccinale) au fil du temps et selon les régions. L'absence de visualisation claire ralentit la prise de décision.

Pourquoi ce problème est-il important ?

Le paludisme représente encore une des premières causes de mortalité infantile en Afrique subsaharienne. La mortalité maternelle reste élevée dans les zones rurales faute de suivi et d'anticipation. Des données bien visualisées permettent d'orienter les ressources là où elles sont le plus nécessaires.

Qui pourrait utiliser la solution ?

Ministères de la Santé, ONG (MSF, Croix-Rouge sénégalaise), chercheurs en santé publique, journalistes de données, étudiants en médecine ou en data.

Quelle décision ou automatisation le projet doit-il faciliter ?

Identifier les régions ou les périodes à risque élevé, comparer l'évolution entre pays d'Afrique de l'Ouest, et fournir un tableau de bord interactif réutilisable.

7. Objectif général

L'objectif du projet est de concevoir et déployer un tableau de bord analytique interactif permettant de visualiser et d'interpréter l'évolution des principaux indicateurs de santé publique (paludisme, mortalité maternelle) au Sénégal et dans plusieurs pays d'Afrique de l'Ouest, à partir de données open source.

8. Objectifs spécifiques

Lister les tâches concrètes attendues :

- Charger et explorer des jeux de données open source provenant de l'OMS, Our World in Data ou Africa CDC
- Nettoyer et normaliser les données (valeurs manquantes, doublons, formats de dates, harmonisation des noms de pays)
- Réaliser une analyse exploratoire des données (EDA) : tendances temporelles, comparaisons régionales, corrélations
- Construire un tableau de bord interactif avec Power BI, Tableau Public ou Streamlit
- Identifier les zones géographiques et les périodes les plus critiques
- Documenter la méthodologie, les choix techniques et les limites de l'analyse

9. Description détaillée du projet

L'apprenant devra construire un pipeline d'analyse de données de bout en bout, depuis la collecte des données brutes jusqu'à la production d'un tableau de bord interactif.

Type de données utilisées :

Données tabulaires (CSV, Excel) contenant des indicateurs sanitaires annuels ou mensuels : incidence du paludisme pour 1 000 habitants, nombre de décès liés au paludisme, taux de mortalité maternelle (pour 100 000 naissances vivantes), couverture vaccinale, accès aux soins prénataux. Les données couvrent le Sénégal et d'autres pays d'Afrique de l'Ouest (Guinée, Mali, Burkina Faso, Côte d'Ivoire) sur une période allant de 2000 à 2022.

Tâche principale :

Développement d'un tableau de bord analytique multi-onglets permettant : (1) la visualisation de l'évolution temporelle des indicateurs, (2) la comparaison entre pays, (3) une carte choroplèthe des régions sénégalaises si les données géographiques sont disponibles.

Fonctionnement attendu du système final :

Un tableau de bord interactif (exportable en HTML ou publié sur Tableau Public / Streamlit Cloud) permettant à un utilisateur non-technique de filtrer par pays, par indicateur et par période, et d'obtenir une lecture claire des tendances.

Contraintes techniques importantes :

- Utiliser uniquement des librairies Python open source (pandas, matplotlib, seaborn, plotly)
- Le tableau de bord doit être reproductible depuis le dépôt GitHub sans configuration complexe
- Toutes les transformations de données doivent être documentées et scriptées

10. Données à utiliser

Élément	Description
Nom du dataset	WHO Global Health Observatory – Malaria & Maternal Health Indicators
Source	OMS GHO : https://www.who.int/data/gho Malaria (CSV direct) : https://ourworldindata.org/grapher/incidence-of-malaria.csv Mortalité maternelle (CSV direct) : https://ourworldindata.org/grapher/maternal-mortality.csv Soins prénataux (CSV direct) : https://ourworldindata.org/grapher/share-of-mothers-receiving-at-least-one-antenatal-visit-during-pregnancy.csv
Type de données	Tabulaire (CSV/Excel)
Taille approximative	Environ 5 000 à 20 000 lignes selon les indicateurs sélectionnés
Licence	CC BY 4.0 (Our World in Data) / Open Data OMS

Variables principales	Pays, année, indicateur, valeur, région OMS, groupe de revenus
Variable cible	Incidence paludisme, taux mortalité maternelle, couverture soins prénataux

Dataset complémentaire recommandé :

- Africa CDC Open Data : <https://africacdc.org/resources/> (telecharger via la page Resources)
- DHIS2 Sénégal (données désagrégées par région) : <https://dhis2.org>
- Kaggle – Malaria Africa (recherche directe) :
<https://www.kaggle.com/datasets/search?q=malaria+africa> | Maternal Mortality :
<https://www.kaggle.com/datasets/search?q=maternal+mortality+sub-saharan+africa>

11. langages et outils à utiliser

Tous les outils recommandés sont accessibles gratuitement.

- Python 3.x (pandas, numpy, matplotlib, seaborn, plotly)
- Jupyter Notebook (exploration et EDA)
- Power BI Desktop (gratuit) ou Tableau Public (gratuit) pour le tableau de bord final
- Streamlit (alternative Python gratuite pour le déploiement du dashboard)
- Git et GitHub (versioning et remise du projet)
- VS Code ou PyCharm Community (IDE)

12. Approche méthodologique attendue

Les apprenants devront suivre les étapes suivantes :

- Compréhension du problème : lire la documentation des datasets, identifier les indicateurs pertinents
- Chargement des données : téléchargement des fichiers CSV, importation avec pandas
- Analyse exploratoire (EDA) : statistiques descriptives, détection des valeurs manquantes et des anomalies
- Nettoyage et prétraitement : suppression des doublons, remplacement des valeurs manquantes, normalisation
- Construction du tableau de bord : choix des visualisations, mise en page, filtres interactifs
- Interprétation des résultats : formulation d'insights clés et de recommandations
- Analyse des erreurs et limites : biais des données, lacunes géographiques, périodes manquantes
- Déploiement simple : publication sur Tableau Public ou Streamlit Cloud
- Documentation et présentation : rédaction du rapport, préparation des slides

13. Environnement de développement

- Python 3.10+ avec environnement virtuel (venv ou conda)
- Jupyter Notebook ou JupyterLab
- VS Code avec extensions Python et Jupyter
- Power BI Desktop (Windows) ou Tableau Public (multiplateforme)
- Git installé localement

14. Environnement de déploiement

Le déploiement doit rester simple et gratuit.

- Tableau Public (<https://public.tableau.com>) : publication gratuite du tableau de bord en ligne
- Streamlit Community Cloud (<https://streamlit.io/cloud>) : déploiement gratuit d'une application Python interactive
- GitHub Pages : pour une version HTML statique exportée

Exigence minimale :

Le projet doit fournir une démonstration fonctionnelle permettant à un utilisateur de tester le tableau de bord sur les données fournies, avec au moins un filtre interactif (pays, indicateur ou période).

15. Livrables attendus

- Code source Python propre et commenté (notebooks + scripts)
- Script de téléchargement ou jeu de données inclus dans le dépôt
- Tableau de bord interactif (lien Tableau Public ou application Streamlit déployée)
- Rapport technique (voir structure ci-dessous)
- Présentation finale (slides)
- Fichier README.md décrivant le projet, les instructions d'installation et de lancement

Le rapport technique doit contenir :

- Description du problème et du contexte sanitaire
- Description des données (sources, structure, qualité)
- Méthodologie d'analyse
- Langages et outils utilisés
- Résultats et insights clés
- Analyse des erreurs et des biais
- Limites du projet
- Perspectives d'amélioration

16. Critères d'évaluation

Critère	Pondération
---------	-------------

Compréhension du problème et du contexte sanitaire	10 pts
Qualité de l'analyse exploratoire des données (EDA)	10 pts
Prétraitement et préparation des données	10 pts
Pertinence du choix des outils et des visualisations	10 pts
Qualité et lisibilité du tableau de bord	15 pts
Pertinence des insights et de l'interprétation	15 pts
Analyse des erreurs, biais et limites	10 pts
Démonstration et déploiement	10 pts
Qualité du code et reproductibilité	5 pts
Qualité du rapport et de la présentation	5 pts
TOTAL	100 pts

18. Contraintes techniques obligatoires

- Utiliser uniquement des données open source ou librement accessibles
- Utiliser uniquement des librairies et outils open source
- Ne pas dépendre d'API propriétaires payantes
- Le projet doit être réalisable en local (sans solution cloud obligatoire)
- Le code doit permettre de relancer l'analyse sans configuration complexe
- Toutes les dépendances doivent être listées dans un fichier requirements.txt

19. Contraintes éthiques et limites

- Respect de la confidentialité : utiliser uniquement des données agrégées et anonymisées
- Identification des biais possibles dans les datasets (sous-déclaration dans certaines régions, données manquantes pour les zones rurales)
- Transparence sur les performances réelles de l'analyse et ses limites
- Ne pas extrapoler les résultats au-delà du périmètre des données disponibles
- Signaler clairement les périodes ou régions pour lesquelles les données sont incomplètes
- Éviter toute interprétation stigmatisante des résultats par pays ou ethnie

20. Ressources recommandées

- WHO Global Health Observatory : <https://www.who.int/data/gho>
- Our World in Data – Malaria : <https://ourworldindata.org/malaria>
- Our World in Data – Maternal Mortality : <https://ourworldindata.org/maternal-mortality>
- Africa CDC Open Data : <https://africacdc.org>
- Documentation Pandas : <https://pandas.pydata.org/docs>
- Documentation Plotly / Dash : <https://plotly.com/python>
- Tutoriels Streamlit : <https://docs.streamlit.io>
- Tableau Public : <https://public.tableau.com>
- Cours Python pour la Data Analysis – OpenClassrooms (gratuit)

21. Format de remise

Les apprenants devront remettre :

- Un lien vers le dépôt GitHub public contenant l'ensemble du code, des données et de la documentation
- Un rapport PDF de 5 à 10 pages
- Une présentation de 5 à 8 slides (PowerPoint, Google Slides ou PDF)
- Un lien vers le tableau de bord déployé (Tableau Public ou Streamlit Cloud)
- Une courte démonstration vidéo ou en présentiel de 5 à 10 minutes